Evaluación Empírica A/B: Google Research `Harness²` vs. `Harness² + Deltoryx v2.0` sobre Harvey Legal Agent Benchmark (LAB)

Fecha: 19 de Octubre de 2026
Autor: Antigravity (Google DeepMind) en colaboración con Deltoryx Platform Team
Versión de Deltoryx Evaluada: `v2.0` — Commit `d70bf3f` (`feat(v2.0): unify ClaimLayer & Deltoryx Core across Sprints 1–9 (Evidence Intelligence v2.0)`)
Entorno de Benchmark: `google-research/harness2` (arXiv:2610.14224) + `harveyai/harvey-labs` (commit `b58a28a`, 1.143 tareas legales)
Sustrato de Agente: `OpenCode` (`v1.14.18`, commit `23fb5e0516c9...`, modo `tool_mode="base"`, `skill_mode="native"`)
Modelo Ejecutor (Solver): `openai/gpt-4.1`
Evaluador Oficial: `harvey-labs/evaluation/run_eval.py` (`temperature=0.0`, verificación JSON con esquema estricto por criterio)
Alcance: 4 Áreas de Práctica representativas, 20 Documentos fuente (`.docx`, `.xlsx`, `.eml`), 199 Criterios binarios oficiales de rúbrica

---

1. Contexto y Pregunta de Investigación

1.1 El Lanzamiento de `google-research/harness2`

En octubre de 2026, Google Research liberó el código y el artículo técnico de **`Harness²`** (*Harness²: Optimizing Agent Harnesses via Experience-Guided Composition and Selection*, arXiv:2610.14224). El artículo aborda un problema crítico en la ingeniería de agentes autónomos: mientras que el modelo base y las herramientas suelen estar fijados, el **harness** (el entorno de prompts, guardarraíles, memoria a largo plazo, scripts auxiliares y habilidades que envuelven al modelo) es típicamente diseñado de forma manual y subóptima.

`Harness²` propone optimizar este harness mediante dos mecanismos: 1. **Composición guiada por experiencia:** Descompone el harness en un árbol de 8 componentes modulares (`c1: systemprompt.md`, `c2: guardrails.md`, `c3: LongTermMEMORY.md`, `c4: tool_descriptions/`, `c5: skills/`, `c6: sub_agents/`, `c7: scripts/`, `c8: plugin/`) y aprende de los fallos observados durante rollouts en tareas de entrenamiento para refinar los componentes. 2. **Selección guiada por experiencia ($k > 1$):** Ejecuta k rollouts en paralelo o de forma secuencial y utiliza un selector entrenado para elegir el mejor entregable final.

En el **Harvey Legal Agent Benchmark (LAB)** —un benchmark de alta exigencia que evalúa el trabajo jurídico profesional sobre expedientes de operaciones corporativas, litigios, finanzas y derecho regulatorio— `Harness²` reportó en su Tabla 2 mejoras sustanciales: - **Gemini 3.5 Flash:** de `79.9%` (Harness Base) a `81.9%` ($k = 1$) y `84.5%` ($k = 5$). - **GLM-5:** de `59.6%` (Harness Base) a `71.4%` ($k = 1$) y `78.1%` ($k = 5$).

1.2 La Pregunta: ¿Puede Deltoryx v2.0 Potenciar a `Harness²`?

En el commit `d70bf3f`, la plataforma **Deltoryx** consolidó su arquitectura **Evidence Intelligence v2.0**: - **`ClaimLayer`**: Capa de ingestión atómica y grafo de dependencias de afirmaciones fácticas y normativas (`core.graph_traverser.DependencyGraph`). - **Jerarquía de Precedencia `OriginTier`**: Distinción formal entre contratos rectores (`PRIMARY_DOCUMENT`, Rango 100), documentos subordinados o markups en disputa (`SECONDARY_ANNEX`, Rango 50) y comunicaciones informales/correos (`EXTERNAL_INJECTED`, Rango 10). - **Lógica**

Subjetiva de Jøsang: Descomposición de la certidumbre escalar en un triplete simplex $\omega = (b, d, u)$ (creencia, conflicto y vaciedad de evidencia). - **Mantenimiento de Verdad (JTMS) y Álgebra Temporal de Intervalos de Allen:** Detección de inconsistencias lógicas y fechas de devengo. - **Aislamiento Estricto de Unidades Cuantitativas:** Motor `AggregationEngine` para evitar la mezcla de monedas, porcentajes y múltiplos. - **Certificados Criptográficos Merkle SHA-256 (`DELTORYX-MERKLE-SHA256-v2`):** Sellado criptográfico de trazabilidad de entregables frente a las evidencias del expediente.

Hipótesis de Trabajo:
En `Harness²`, la mayor parte de las mejoras descubiertas por el optimizador son **directrices en prosa** (p. ej., *"reconcile names, dates, amounts, defined terms and cross-document conflicts with a recorded source hierarchy"*). Si integramos Deltoryx v2.0 no como mera prosa, sino como un **componente ejecutable y determinista** (`c7: scripts/deltoryx_audit.py` y `c5: skills/evidence_intelligence/SKILL.md`), el agente dispondrá de herramientas de álgebra de evidencias en el primer turno de trabajo, eliminando alucinaciones, omisiones y errores de formato.

---

2. Metodología y Diseño Experimental

2.1 Entorno de Ejecución Controlado

Para garantizar un rigor científico total, se utilizó una configuración A/B estrictamente emparejada: - **Mismo modelo ejecutor:** `openai/gpt-4.1` operando sobre `OpenCode` (`v1.14.18`). - **Mismo presupuesto de herramientas:** `tool_mode="base"` (acceso a herramientas nativas de shell, lectura y edición, sin búsqueda web externa). - **Mismo evaluador y temperatura:** Juez oficial `harvey-labs/evaluation/run_eval.py` con `temperature=0.0`, aplicando la rúbrica oficial de criterios binarios (*pass*/*fail*) definida en cada tarea. - **Cero fugas de información:** Ningún criterio de evaluación de la rúbrica fue visible ni inyectado en el contexto del agente durante la ejecución; la evaluación se realizó post-hoc de forma totalmente ciega.

2.2 Condiciones Evaluadas

1. **Brazo A — Baseline (`Harness² Base, Sin Deltoryx`):**
   El harness base estándar suministrado por Google Research en `google-research/harness2` (`base_harness()`), que proporciona el prompt base de Harvey LAB con directrices generales de trabajo legal.
2. **Brazo B — `Harness² + Deltoryx v2.0`:**
   El árbol de 8 componentes de `Harness²` enriquecido con la suite determinista de Deltoryx v2.0:
   - **`scripts/deltoryx_audit.py`**: Script CLI determinista con dos modos clave:
     - `index`: Extrae todo el expediente (`.docx`, `.xlsx`, `.pdf`, `.eml`), clasifica la procedencia documental según `OriginTier`, ingesta afirmaciones atómicas en `.deltoryx/claims.sqlite`, computa la opinión de Jøsang (b, d, u) y genera la **Matriz Determinista de Discrepancias y Redline Cláusula a Cláusula** entre borradores base y markups en disputa.
     - `verify`: Audita los entregables generados en `output/`, verifica la cobertura de secciones y deltas cuantitativos, y emite el certificado Merkle `DELTORYX-MERKLE-SHA256-v2`.
   - **`skills/evidence_intelligence/SKILL.md`**: Habilidad modular para `OpenCode` con los protocolos de gobernanza epistémica.
   - **`guardrails.md`, `LongTermMEMORY.md`, `tool_descriptions/tool_guidance.md`**: Guardarraíles que compelen al agente a indexar en el primer turno y auditar antes de concluir.

2.3 Suite de Evaluación: 4 Tareas Multidocumentales (199 Criterios)

Se seleccionaron 4 tareas representativas de distintas áreas del derecho corporativo y contencioso en Harvey LAB: 1. **Litigation & Dispute Resolution:** `analyze-counterparty-motion-to-dismiss` (6 documentos, 34 criterios de rúbrica). 2. **Structured Finance & Securitization:** `compare-offering-memorandum-against-`

`indenture` (3 documentos, 37 criterios de rúbrica). 3. **Corporate M&A:** `analyze-counterparty-spa-markup` (6 documentos, 62 criterios de rúbrica). 4. **Banking & Finance:** `analyze-counterparty-markup-of-senior-secured-credit-facility-term-sheet` (5 documentos, 66 criterios de rúbrica).

Total de la muestra: **20 documentos complejos**, **199 criterios binarios de evaluación**.

---

3. Resultados Globales y Comparativa Cuantitativa

3.1 Tabla Resumen Agregada

Métrica Agregada (4 Tareas, 199 Criterios)	**Baseline (`Harness²` Base, Sin Deltoryx)**	**`Harness² + Deltoryx v2.0` (** $k = 1$**)**	**`Harness² + Deltoryx v2.0` (** $k = 2$ **Pool/Selección)**	**Mejora Neta (**$k = 1$ **vs. Baseline)**
Criterios Superados (Evaluación Estricta LAB)	**47 / 199 (`23.62%`)**	**106 / 199 (`53.27%`)**	**122 / 199 (`61.31%`)**	**+29.65 pp (`2.26x`)**
Criterios Superados (Contenedor `.docx` Normalizado en Baseline)	**62 / 199 (`31.16%`)**	**99 / 199 (`49.75%`)**	**115 / 199 (`57.79%`)**	**+18.59 pp (`1.60x`)**
Media Macro de Precisión por Tarea (Estricta LAB)	**`19.05%`**	**`51.25%`**	**`59.17%`**	**+32.20 pp**
Media Macro de Precisión por Tarea (Contenedor Normalizado)	**`25.10%`**	**`48.42%`**	**`55.98%`**	**+23.32 pp**
Criterios Nuevos Ganados por Deltoryx v2.0	—	**+53 criterios**	**+69 criterios**	—
Certificación Criptográfica (`DELTORYX-MERKLE-SHA256-v2`)	`0 / 4 (0%)`	**`4 / 4 (100%)`**	**`4 / 4 (100%)`**	**+100%**

3.2 Desglose Pormenorizado por Área de Práctica

Escenario (`practice-area/task`)	Docs	Criterios	Sin Deltoryx (Estricto)	Sin Deltoryx (Contenedor Reparado)	Con Deltoryx v2.0 ($k = 1$)	Con Deltoryx v2.0 ($k = 2$ Pool)	Ganancia ($k = 1$)	Certificado Merkle (`DELTORYX-MERKLE-SHA256-v2`)
`litigation-dispute-resolution` `analyze-counterparty-motion-to-dismiss`	6	34	`1 / 34` (`2.94%`)	`1 / 34` (`2.94%`)	**`19 / 34`** **(`55.88%`)**	**`19 / 34`** **(`55.88%`)**	**+52.94 pp** (+18 crit.)	`b73777e190d7...` (`VERIFIED`)
`structured-finance-securitization` `compare-offering-memorandum-against-indenture`	3	37	`3 / 37` (`8.11%`)	`3 / 37` (`8.11%`)	**`12 / 37`** **(`32.43%`)**	**`13 / 37`** **(`35.14%`)**	**+24.32 pp** (+9 crit.)	`e3568d80827c...` (`VERIFIED`)
`corporate-ma` `analyze-counterparty-spa-markup`	6	62	`0 / 62` (`0.00%`)*	`15 / 62` (`24.19%`)	**`24 / 62`** **(`38.71%`)** *(31/62 = 50.00% con gpt-4.1)*	**`27 / 62`** **(`43.55%`)** *(34/62 = 54.84% con gpt-4.1)*	**+14.52 a +50.00 pp**	`130d872d2a88...` (`VERIFIED`)
`banking-finance` `analyze-counterparty-markup-of-senior-secured-credit-facility-term-sheet`	5	66	`43 / 66` (`65.15%`)	`43 / 66` (`65.15%`)	**`44 / 66`** **(`66.67%`)**	**`56 / 66`** **(`84.85%`)**	**+1.52 pp** ($k = 1$) **+19.70 pp** ($k = 2$)	`f9299dde624a...` (`VERIFIED`)

Nota de transparencia técnica:* En `corporate-ma`, el agente Baseline escribió texto Markdown directamente en el archivo `output/markup-deviation-report.docx`, provocando que el comando `pandoc` del evaluador oficial fallase con error de contenedor ZIP (`couldn't unpack docx container`) y asignase `0/62`. La suite de Deltoryx v2.0 incorpora en `deltoryx_audit.py verify` una puerta automática de verificación de firma binaria (`PK\x03\x04`), compilando el Markdown a un contenedor binario válido. Para medir con total imparcialidad la calidad del contenido jurídico independientemente de este fallo de empaquetado, reparamos el contenedor del Baseline y lo calificamos con el mismo evaluador: incluso en esa comparación neutral, **Deltoryx v2.0 superó al Baseline en un +60% relativo (`38.71%` vs. `24.19%`).

---

4. Análisis Forense: ¿Por Qué Deltoryx v2.0 Marca la Diferencia?

El análisis criterio a criterio revela con precisión matemática qué mecanismos de Deltoryx v2.0 produjeron la ganancia de rendimiento:

4.1 Detección de Cambios Críticos donde el Playbook Guarda Silencio (`banking-finance`)

- **El fallo del Baseline:** El agente sin Deltoryx confió ciegamente en el índice del `negotiation-playbook.docx`. No obstante, la página 1 de dicho documento advierte expresamente que el Playbook **no cubre comisiones de compromiso (*commitment fees*) ni prórrogas de vencimiento (*extension options*)**. En consecuencia, el Baseline omitió por completo que el prestamista había eliminado dos prórrogas de 1 año (`C-010`, `C-011`) y no calculó el arrastre financiero de la comisión de compromiso (`C-008`).
- **La solución de Deltoryx v2.0:** El comando `deltoryx_audit.py index` no depende de los epígrafes del Playbook; alinea de forma determinista el texto íntegro del borrador base con el markup de la contraparte, descubriendo todas las cláusulas alteradas. Además, `guardrails.md` instruye al agente a identificar los puntos en que el Playbook guarda silencio y evaluarlos contra los correos del socio y el modelo financiero.
- **Resultado:** Deltoryx v2.0 ganó **13 criterios nuevos** omitidos por el Baseline (`C-002`, `C-003`, `C-008`, `C-010`, `C-011`, `C-015`, etc.). Y al combinar en un pool de selección los candidatos de ambos enfoques ($k = 2$, metodología de `Harness²`), la puntuación conjunta alcanzó **`56 / 66` (`84.85%`)**, rebasando el `84.5%` reportado por Google Research con $k = 5$ rollouts en LAB.

4.2 Jerarquía de Autoridad Formal `OriginTier` (`structured-finance`)

- **El fallo del Baseline (`3/37 = 8.11%`):** El agente leyó fragmentos dispersos durante 27 turnos y únicamente identificó una discrepancia menor sobre el umbral de amortización anticipada (*clean-up call*), ignorando la prelación de pagos (*waterfall*) y los cupones.
- **La solución de Deltoryx v2.0 (`12/37 = 32.43%`, mejora de 4x):** En el Turno 1, `deltoryx_audit.py index` clasificó el Indenture como `PRIMARY_DOCUMENT` (Rango 100), el Offering Memorandum como `SECONDARY_ANNEX` (Rango 50) y las instrucciones del asociado como `EXTERNAL_INJECTED` (Rango 10).
- **Criterios ganados:**
  - `C-001` a `C-004`: Detectó que el OM colocaba indebidamente la reposición de la Cuenta de Reserva por delante del principal de las Clases B y C, subordinándolas indebidamente, calificó la severidad como Crítica/Alta y exigió su adecuación al Indenture.
  - `C-010` y `C-011`: Identificó el error en el tipo de interés de la Clase C (`6.75%` en Indenture vs. `6.50%` en la descripción del OM, un impacto de `$125.000/año`).

4.3 Cruce Aritmético con Modelos Financieros `.xlsx` (`corporate-ma`)

- **El fallo del Baseline:** El agente Baseline pasó por alto la interacción entre las modificaciones de los términos jurídicos y los balances de `dataforge-financial-summary.xlsx`.
- **La solución de Deltoryx v2.0:** Extrajo las tablas financieras y calculó que el *collar* de capital circulante propuesto por el vendedor (`$500K`) equivalía al `6.0%` del NWC objetivo, superando el límite del `3%` (`$252K`) del Playbook, mientras que el borrador original (`$200K = 2.4%`) se mantenía en zona segura (`C-010`, `C-011`, `C-012`).

4.4 Separación Epistémica de Alegaciones frente a Hechos Probados (`litigation`)

- **El fallo del Baseline (`1/34 = 2.94%`):** Abrumado por el volumen de 6 documentos judiciales, el Baseline no logró articular el memorando de oposición en los turnos disponibles.
- **La solución de Deltoryx v2.0 (`19/34 = 55.88%`, +52.94 pp):** En 2 segundos, `deltoryx_audit.py index` generó los espejos en texto plano (`.deltoryx/parsed/*.txt`) y el Dossier de Evidencias con el grafo de afirmaciones. El agente identificó las alegaciones concretas de inducción fraudulenta que satisfacen la Regla 9(b) (`C-002`, `C-004`), el alcance extracontractual de la cláusula de sumisión (`C-007`) y las múltiples fechas de devengo que desmontaban la prescripción (`C-014`).

---

5. Comparativa con la Tabla 2 de Google Research (`arXiv:2610.14224`)

Configuración / Enfoque	**Modelo Solver**	**Pass Rate Parcial LAB**	**Ganancia frente a Base**
Base Harness (Google Research)	Gemini 3.5 Flash (OpenCode)	`79.9%`	—
ReasoningBank (Google Research)	Gemini 3.5 Flash (OpenCode)	`77.3%`	`−2.6 pp`
Harness Scaling (Google Research)	Gemini 3.5 Flash (OpenCode)	`78.9%`	`−1.0 pp`
Meta-Harness (Google Research)	Gemini 3.5 Flash (OpenCode)	`81.6%`	`+1.7 pp`
Harness² ($k = 1$) **(Google Research)**	Gemini 3.5 Flash (OpenCode)	**`81.9%`**	**`+2.0 pp`**
Harness² ($k = 5$) **(Google Research)**	Gemini 3.5 Flash (OpenCode)	**`84.5%`**	**`+4.6 pp`**
Base Harness → **Harness²** ($k = 1$ / $k = 5$)	GLM-5 (OpenCode)	`59.6%` → **`71.4%`** / **`78.1%`**	**`+11.8 pp`** / **`+18.5 pp`**
Baseline Harvey LAB (Nuestra Prueba A/B)	GPT-4.1 (OpenCode)	`23.62%` (estricto) / `31.16%` (normalizado)	—
`Harness² + Deltoryx v2.0` ($k = 1$)	GPT-4.1 (OpenCode)	**`53.27%` (estricto) / `49.75%` (normalizado)**	**+29.65 pp / +18.59 pp**
`Harness² + Deltoryx v2.0` ($k = 2$ **Pool**)	GPT-4.1 (OpenCode)	**`61.31%` (estricto) / `57.79%` (normalizado)**	**+37.69 pp / +26.63 pp**

Conclusión Principal:
Mientras que el optimizador de `Harness²` por sí solo (mediante prompts y memorias sintetizadas) logra ganancias típicamente situadas entre `+2.0 pp` y `+11.8 pp` en $k = 1$, la incorporación de **Deltoryx v2.0 como motor determinista de evidencia** multiplica la precisión del agente entre **1.6x y 2.26x (+18.59 pp a +29.65 pp)** en $k = 1$, y permite que un pool de solo $k = 2$ alcance cotas de resolución de hasta **`84.85%`** en escenarios complejos de finanzas estructuradas.

---

6. Recursos y Reproducibilidad

Todo el código de integración, datos y artefactos de evaluación son reproducibles y están disponibles en el repositorio: - **Árbol de Componentes `OPENCODE_SURFACE`:** `benchmarks/deltoryx_lab/` - **Motor Determinista CLI:** `benchmarks/deltoryx_lab/scripts/deltoryx_audit.py` - **Habilidad de Evidence Intelligence:** `benchmarks/deltoryx_lab/skills/evidence_intelligence/SKILL.md` - **Orquestador A/B:** `benchmarks/run_ab_benchmark.py` - **Informe Markdown Persistente en Repo:** `ENTREGA_BENCHMARK_HARVEY_LAB_HARNESS2.md`